HACKATHON ISAC 2026 · RETO DIABLOS ROJOS DEL MÉXICO · DOCUMENTO TÉCNICO

# DIABLOS STUFF+

Calidad de lanzamiento ajustada por la altitud del Estadio Alfredo Harp Helú. Qué lanzadores sufren los 2,240 metros, cuáles aguantan y qué perfil te conviene buscar.

**635,002**
lanzamientos de la LMB, 2024 a 2026, medidos con Trackman

**561**
lanzadores comparados entre el nivel del mar y el Harp Helú

**21**
lanzadores aguantan la altura, pierden menos de media carrera por cada 100 lanzamientos

Trabajo independiente de los participantes. No es un producto oficial de ISAC ni del club. Usamos los datos de la LMB sólo para esta competencia y aquí presentamos resultados, no datos. La liga anonimizó a los lanzadores.

# RESUMEN

Los modelos Stuff+ califican qué tan difícil de batear es un lanzamiento a partir de su física. El problema es que se construyeron en estadios a nivel del mar. El Harp Helú está a 2,240 metros, con 20 % menos aire, y ahí la pelota se mueve menos. Construimos un Stuff+ para la LMB en el que **la altitud no es una variable del modelo sino una transformación física**. Lo hicimos en cuatro pasos.

1. **Le damos un valor a cada lanzamiento.** Cada lanzamiento cambia el conteo de bolas y strikes, y cada conteo vale cierto número de carreras para el bateador. La diferencia es cuántas carreras le quitó o le dio ese lanzamiento al rival. Eso es lo que el modelo aprende a predecir.
2. **Entrenamos un modelo que sólo ve la física.** Es un modelo de árboles de decisión (LightGBM) que recibe 16 medidas de Trackman, como la velocidad, el giro, el movimiento y el punto de salida. No ve dónde cayó la pelota, ni el estadio, ni al bateador. Pasamos su predicción a una escala donde 100 es el promedio de la liga y cada 10 puntos es una desviación estándar. Eso es Stuff+.
3. **Lo probamos con lanzadores que no vio.** Partimos a los lanzadores en cuatro grupos, entrenamos con tres y calificamos al cuarto. Cada calificación sale de un modelo que nunca vio a ese lanzador, y la comparamos contra un modelo nulo que sólo conoce el conteo.
4. **Volamos el mismo lanzamiento en otro aire.** Medimos qué tan denso estaba el aire en cada juego con el frenado de la pelota, simulamos cómo habría volado cada lanzamiento con el aire del Harp Helú y lo calificamos otra vez. La diferencia entre las dos calificaciones es el efecto de la altitud.

Encontramos cuatro cosas que cambian tus decisiones.

- **Todo lanzamiento pierde en altura, pero no lo mismo.** La recta pierde 11.7 puntos de Stuff+ (1.6 carreras más por cada 100 lanzamientos) y el cutter 3.0. Las mejores rectas pierden 19.
- **De 561 lanzadores, sólo 21 aguantan la altura**, es decir, pierden menos de media carrera por cada 100 lanzamientos. Todos tiran slider, más de la mitad tira cutter (contra 18 % de la liga) y provocan más rodados.
- **Probamos las cuatro hipótesis del reto.** H1 y H4 se confirman. H2 y H3 se confirman en parte.
- **Un Causal Forest sobre carreras reales confirma el costo de la altura**, 1.52 carreras más por cada 100 lanzamientos, sin usar Stuff+. La física del lanzamiento explica cerca del 40 % y el resto es el batazo, que en altura vuela más. Las carreras solas no alcanzan para separar a un lanzador de otro, y por eso necesitas la física.

# 1. PLANTEAMIENTO

## 1.1 LA PREGUNTA DEL CLUB

¿Qué lanzadores sufren más la altitud y cuáles son los más consistentes? De esa respuesta salen tus fichajes, tu rotación en casa y el desarrollo de tus prospectos.

## 1.2 POR QUÉ IMPORTA LA ALTITUD

Una pelota que gira desvía el aire hacia un lado, y el aire la empuja hacia el otro. Es el efecto Magnus. Ese empuje produce el movimiento que engaña al bateador, y crece con la densidad del aire. Con menos aire hay menos empuje, menos movimiento y menos engaño. A la vez, el aire frena menos y los batazos llegan más lejos. Alan Nathan estima que en Coors Field, a 1,609 metros, un lanzamiento con 18 pulgadas de quiebre se mueve 14 o 15. El Harp Helú está 631 metros más arriba.

## 1.3 LAS HIPÓTESIS DEL RETO

| | HIPÓTESIS | CÓMO LA PROBAMOS |
|---|---|---|
| H1 | La baja densidad reduce el movimiento que produce el giro | Física contra Nathan y pérdida de Stuff+ por tipo, con intervalos |
| H2 | Los lanzamientos de diferencial de velocidad ganan valor relativo | El cambio contra la recta del mismo lanzador |
| H3 | Los lanzadores de rodados valen más en altura | Pendiente de carreras contra rodados en cada entorno |
| H4 | El giro por sí solo no predice Stuff+ | Peso en el modelo y experimento controlado |

# 2. DATOS Y SUPUESTOS

ISAC entregó 635,002 lanzamientos medidos con Trackman en tres temporadas, con identificadores anónimos de juego, lanzador, bateador y receptor. El conjunto **no dice en qué estadio se lanzó**. Sólo trae una categoría de altitud con tres niveles (nivel del mar, altitud media y altitud extrema).

| LIMITACIÓN | CÓMO LA RESOLVIMOS |
|---|---|
| No hay estadio ni altitud | Medimos la densidad del aire en la trayectoria (sección 3.2) |
| No hay corredores en base | Valor de carrera sobre los 12 conteos posibles |
| No hay fecha ni número de lanzamiento | Reconstruimos el orden, el archivo viene cronológico por juego |
| `is_hit_by_pitch` vale cero en todas las filas | Lo reconstruimos desde `PitchCall` |
| Hay tipos de lanzamiento residuales | Los agrupamos en siete tipos estables |

Trabajamos con cuatro supuestos. **S1.** Un lanzador suelta la pelota igual en cualquier estadio. La velocidad y las vueltas que le da no dependen de la altura. Lo comprobamos comparando a cada lanzador consigo mismo. Entre nivel del mar y altitud extrema sus vueltas cambian 0.5 %, su eficiencia de giro 0.3 % y su velocidad de salida 0.1 %. **S2.** Entonces lo que cambia entre estadios es el camino de la pelota después de soltarla, y eso lo decide el aire. **S3.** Calificamos lo que se espera de un lanzamiento, no lo que pasó en esa jugada. Un mismo lanzamiento puede terminar en ponche o en hit según el bateador y la suerte, así que medimos su valor promedio en carreras según el conteo. **S4.** El 100 es el promedio de la liga tal como lanzó, en sus tres tipos de estadio. Por eso a nivel del mar el lanzamiento típico queda arriba de 100 y en altura abajo.

# 3. METODOLOGÍA

## 3.1 LA IDEA EN CUATRO PASOS

La decisión central es que **la altitud nunca entra como variable del modelo de calidad**. Si entrara, su efecto se mezclaría con quién lanza dónde, porque los lanzadores de los equipos de altura no son una muestra al azar. Y no podrías responder la pregunta que importa. ¿Cuánto valdría en el Harp Helú un lanzamiento que nunca se ha tirado ahí? Los cuatro pasos del Resumen resuelven eso. Esta sección los detalla. La forma de un lanzamiento es cómo se mueve en el camino, cuánto sube o cae y hacia qué lado se va.

## 3.2 LA DENSIDAD DEL AIRE, MEDIDA EN LA TRAYECTORIA

Trackman reporta la aceleración de cada pelota. Le quitamos la gravedad y nos queda la parte aerodinámica. La separamos en una componente paralela a la velocidad (el arrastre) y una perpendicular (el Magnus).

$$\mathbf{a}_{\text{aero}} = \mathbf{a} - \mathbf{g}, \qquad \mathbf{a}_{\text{drag}} = (\mathbf{a}_{\text{aero}} \cdot \hat{\mathbf{v}})\,\hat{\mathbf{v}}, \qquad \mathbf{a}_{\text{M}} = \mathbf{a}_{\text{aero}} - \mathbf{a}_{\text{drag}}$$

El arrastre vale $\tfrac{1}{2}\rho\, C_d A\, v^2/m$. Por eso el cociente $k_{\text{drag}} = \|\mathbf{a}_{\text{drag}}\|/v^2$ es proporcional a $\rho\, C_d$, y lo calculamos para cada lanzamiento. Su mediana por juego, normalizada al nivel del mar, es el **índice de arrastre** $I$ de ese juego.




Índice de arrastre por categoría (mediana por juego). 1.000 es el nivel del mar.

**El arrastre no es la densidad.** A 2,240 metros la atmósfera estándar da $\rho/\rho_0 = 0.802$, pero medimos un índice de 0.853. La causa es aerodinámica. Con menos aire baja el número de Reynolds y sube el coeficiente de arrastre $C_d$. Anclamos un solo exponente $\beta$ a la altitud del Harp Helú.

$$I(h) = \rho_{\text{ISA}}(h)^{\beta}, \qquad \rho_{\text{ISA}}(h) = \left(1 - 2.25577 \times 10^{-5}\, h\right)^{4.25588}, \qquad \beta = 0.7184$$

La prueba es independiente del ajuste. Con ese $\beta$, un estadio a la altura de Coors Field debería dar $I = 0.8931$. La categoría de altitud media de la LMB nunca entró al ajuste y mide 0.8981.

**El movimiento cae más que el arrastre.** Dentro del mismo lanzador y tipo de lanzamiento (1,187 combinaciones en siete niveles de densidad), las dos fuerzas responden distinto.

$$k_{\text{drag}} \propto \rho^{0.96}, \qquad k_{\text{M}} \propto \rho^{1.39}$$

El Magnus responde casi 1.5 veces más fuerte que el arrastre. Como el lanzador le da las mismas vueltas a la pelota en los dos estadios (S1), esa caída del empuje viene

del aire.

## 3.3 TRANSFERENCIA DE FORMA, EL MISMO LANZAMIENTO EN OTRO AIRE

Para cada lanzamiento resolvemos su estado de salida (posición, velocidad y eje de giro) a partir de lo que midió Trackman. Después integramos el vuelo desde la mano hasta el plato con Runge Kutta de cuarto orden y pasos de 2 milisegundos.

$$\frac{d\mathbf{v}}{dt} = -\,k_d\, I\, \|\mathbf{v}\|\, \mathbf{v} \;+\; M\, I^{\gamma}\, \frac{\|\mathbf{v}\|^2}{\|\mathbf{v}_0\|^2}\, \frac{\hat{\boldsymbol{\omega}} \times \mathbf{v}}{\|\hat{\boldsymbol{\omega}} \times \mathbf{v}\|} \;+\; \mathbf{g}$$

Aquí $k_d = 0.001588$ es la mediana de la LMB a nivel del mar y $M$ es la magnitud de Magnus que reproduce la forma medida. Los exponentes $\gamma_v = 1.7$ (vertical) y $\gamma_h = 2.2$ (lateral) los calibramos fuera de muestra (sección 4.1). El eje de giro $\hat{\boldsymbol{\omega}}$ se conserva y la fuerza queda perpendicular a la velocidad todo el vuelo.

**Usamos el simulador sólo para medir diferencias.** No le pedimos que adivine cómo se movió la pelota, eso ya lo midió Trackman. Le pedimos cuánto cambiaría el movimiento al pasar de un aire a otro, y ese cambio se lo sumamos a la medición real.

$$\text{forma}_{\text{HH}} = \text{forma}_{\text{Trackman}} + \left[ f(I_{\text{HH}}) - f(I_{\text{obs}}) \right]$$

Así siempre partimos de lo que midió Trackman, y el único error posible está en cuánto cambia la forma.

## 3.4 EL VALOR EN CARRERAS DE CADA LANZAMIENTO

Sin corredores en base, el estado del turno es el conteo, con 12 combinaciones de bolas y strikes. El valor de un conteo $V(c)$ es el promedio de las carreras de los turnos que pasan por él. Los eventos finales usan pesos lineales (sencillo 0.70, doble 1.00, jonrón 1.65, ponche $-0.27$), recentrados para que el turno promedio de la LMB valga cero. El valor de un lanzamiento es cuánto mueve el turno.

$$\text{RV} = V(c_{\text{después}}) - V(c_{\text{antes}})$$

## 3.5 STUFF+, LOCATION+ Y PITCHING+

Las tres capas predicen el mismo objetivo, el valor esperado en carreras $\widehat{\text{RV}}$, con gradient boosting en LightGBM. Sólo cambia lo que ve cada una.

| CAPA | VARIABLES | QUÉ VE |
|---|---|---|
| Stuff+ | 16 | Sólo física. Velocidad, quiebres, giro, eje, punto de salida, extensión, tiempo de vuelo y eficiencia de giro |
| Location+ | 23 | Además, dónde llegó la pelota, el conteo y el lado del bateador |
| Pitching+ | 33 | Además, el arsenal del lanzador y la secuencia con el lanzamiento anterior |

**Los ángulos de salida y de llegada no entran en ninguna capa**, aunque Trackman los mida en el release. El ángulo con que sale la pelota también dice a dónde va, así que con ellos el modelo aprende puntería en lugar de física. Lo medimos. Con los cuatro ángulos, Stuff+ correlacionaba $-0.70$ con la distancia al centro de la zona, más que el propio Location+ ($-0.53$), y la ubicación en el plato predecía el 58 % de su varianza. Sin ellos, $-0.03$ y prácticamente nada. El reto define Stuff+ como física pura, y la ubicación entra en Location+.

Location+ y Pitching+ usan 500 árboles, tasa de aprendizaje 0.05, 96 hojas, al menos 400 lanzamientos por hoja y regularización $L_2 = 5$. **Stuff+ va mucho más regularizado** (400 árboles, tasa 0.03, 31 hojas, al menos 4,000 lanzamientos por hoja, $L_2 = 50$). Sin ubicación, lo único que le queda para separar lanzamientos es la física, y el punto de salida es casi una firma de cada lanzador. Con hojas chicas el modelo memoriza lanzadores y, con lanzadores nuevos, queda peor que el promedio.

**De dónde sale cada calificación.** Medimos con SHAP cuánto aporta cada grupo de variables a la predicción. Stuff+ es 100 % física, y sus variables más pesadas son cuánta velocidad pierde la pelota en el vuelo, el quiebre vertical, la elevación y el giro. En Location+ la ubicación y el conteo explican el 62 % y la física el 38 %. En Pitching+ la ubicación y el conteo explican el 55 %, la física el 26 % y el arsenal con la secuencia el 19 %.

La función de pérdida es el error cuadrático (L2) sobre el valor en carreras. Pitching+ incluye las variables relacionales de arsenal que pide el reto, todas contra la recta principal del lanzador en esa temporada. Diferencia de velocidad, de elevación y de movimiento lateral, similitud de túnel (qué tan parecido sale de la mano), uso de cada lanzamiento, tamaño del arsenal, lanzamiento anterior y vuelta al orden.

Stuff+ nunca ve ubicación, conteo, bateador ni estadio. Por eso lo puedes transferir. Para saber qué vale un lanzamiento en otro aire, le das la forma transferida y lo vuelves a calificar. La escala sigue la convención sabermétrica.

$$\text{Stuff+} = 100 + 10\, z\left(-\widehat{\text{RV}}\right)$$

Aquí $z$ estandariza con la media y la desviación estándar de la liga. 100 es el promedio y cada 10 puntos son una desviación estándar. El signo se invierte porque menos carreras es mejor para el lanzador. El reto propone que la calificación final sea una combinación ponderada de varios objetivos (swing fallido, persecución, strike cantado, contacto débil, rodado, contacto duro, valor en

carreras). Elegimos predecir directo el valor esperado en carreras porque ya es esa combinación, ponderada por lo que cada resultado vale en el marcador, y así no tienes que inventar pesos. Los ocho modelos de componente sí los entrenamos, y explican de dónde sale cada calificación, pero no entran en el cálculo de Stuff+.

### 3.6 VALIDACIÓN FUERA DE MUESTRA

Calculamos todas las métricas con datos que el modelo no vio. **Holdout de lanzador.** Validación cruzada de 4 pliegues agrupada por lanzador. Ningún lanzador está en entrenamiento y prueba a la vez. **Holdout de temporada.** Entrenamos con 2024 y 2025 y probamos con 2026. **Holdout de parque.** Entrenamos sin altitud extrema y probamos sólo en altitud extrema. **Modelo nulo.** El promedio del valor en carreras por conteo, lo mínimo que sabes sin mirar el lanzamiento. **Calibración.** Agrupamos los lanzamientos por su Stuff+ fuera de muestra y comparamos lo predicho con las carreras que pasaron.

### 3.7 PRUEBAS DE HIPÓTESIS

Medimos toda la incertidumbre con **bootstrap por lanzador** de 2,000 remuestreos. Remuestreamos lanzadores completos y no lanzamientos sueltos, porque los lanzamientos de un mismo lanzador se parecen entre sí y no cuentan como pruebas independientes.

**H1.** Para cada tipo de lanzamiento $t$ calculamos la pérdida media, ponderada por número de lanzamientos, sobre 2,808 combinaciones de lanzador y tipo.

$$\bar{\Delta}_t = \frac{\sum_i n_{it}\,\Delta_{it}}{\sum_i n_{it}}, \qquad \Delta_{it} = \text{Stuff+}_{it}^{\text{HH}} - \text{Stuff+}_{it}^{\text{mar}}$$

Además comparamos el integrador con la cifra de Nathan.

**H2.** Usamos un diseño pareado dentro del lanzador. Para quien tira cambio y recta, $D_i = \Delta_{i,\text{cambio}} - \Delta_{i,\text{recta}}$. Al comparar contra la recta del mismo lanzador se cancela todo lo que es del lanzador y queda sólo el efecto del aire sobre cada forma. Si $D > 0$, el cambio pierde menos que la recta.

**H3.** Tomamos los 333 lanzadores que tiraron al menos 120 veces en cada entorno. Estimamos por mínimos cuadrados ponderados la pendiente de carreras contra rodados en cada entorno $e$.

$$R_{ie} = a_e + b_e\,\text{GB}_i + \varepsilon_{ie}, \qquad H_3 \Leftrightarrow b_{\text{alt}} - b_{\text{mar}} < 0$$

El peso de cada lanzador es $w_i = 2\,(1/n_{i,\text{alt}} + 1/n_{i,\text{mar}})^{-1}$, la precisión de una diferencia.

**H4.** Hicimos dos pruebas. Primero medimos el peso de cada grupo de variables dentro de Stuff+, como la ganancia total de los árboles que las usan. Después corrimos un experimento controlado con el simulador. Movimos una sola perilla (giro o movimiento) y dejamos fijo todo lo demás, algo que los datos de la cancha no permiten. Cada punto es el promedio de 49 variaciones chicas del mismo lanzamiento, y cada variación vuela con un arrastre sacado de la dispersión real entre pelotas, como en el pipeline, donde cada lanzamiento vuela con su propio arrastre medido.

### 3.8 MODELO SECUNDARIO, UN CAUSAL FOREST

Stuff+ valora lanzamientos. Un Causal Forest responde otra cosa, preguntas de qué hubiera pasado. Lo usamos para dos, con Double Machine Learning (Chernozhukov y coautores, 2018) y un bosque causal honesto (Wager y Athey, 2018).

$$Y = \theta(X)\,T + g(X,W) + \varepsilon, \qquad T = m(X,W) + \eta$$

Dos modelos de árboles predicen el resultado $Y$ y la decisión $T$ a partir de los controles $W$, y el bosque estima el efecto $\theta(X)$ sobre lo que esos modelos no explican.

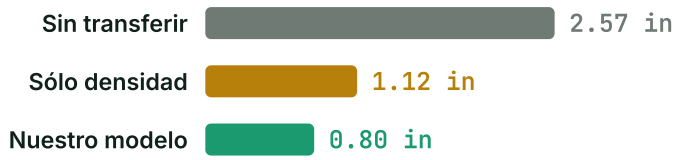
**La pregunta táctica, la que plantea el reto.** ¿Qué hubiera pasado si el pitcher lanzaba slider en vez de cambio en este conteo, contra este bateador? Cada lanzamiento de dos tipos (por ejemplo slider o cambio) es una observación. $T$ es elegir el primero, $Y$ es su valor en carreras, $X$ es el conteo, si el bateador es del mismo lado, el entorno (nivel del mar o altitud extrema) y si el lanzamiento anterior fue recta. $W$ controla lo que confunde la elección, la calidad del lanzador, cuánto usa cada tipo, la vuelta al orden, las manos y la velocidad de su recta. El resultado es una tabla por conteo, lado del bateador y entorno que dice qué lanzamiento conviene, en casa y de visitante. Contrastamos slider contra cambio, slider contra recta, cambio contra recta y curva contra slider.

**La pregunta de entorno.** ¿Cuánto cuesta la altura en carreras reales, y le cuesta distinto a cada lanzador? Cada lanzador con al menos 120 lanzamientos en cada entorno aparece dos veces y se compara consigo mismo. $T$ es lanzar en altura, $Y$ son sus carreras por cada 100 lanzamientos, y $X$ son sus rasgos (Stuff+, velocidad, swings fallidos, rodados, extensión, mano y uso de cada tipo). Para no engañarnos, a cada lanzador le damos el efecto de un bosque que no lo vio y aplicamos la prueba GATES (Chernozhukov y coautores, 2018). Agrupamos por efecto predicho y comprobamos si el castigo observado sube de grupo en grupo.

## 4. VALIDACIÓN

## 4.1 LA TRANSFERENCIA DE FORMA

444 lanzadores tiraron en ambos entornos. Calibramos los exponentes con la mitad y dejamos la otra mitad **sin tocar**. En esas 436 combinaciones predecimos lo que el lanzador tiró en altura a partir de lo que tiró a nivel del mar.




Error medio en elevación, en combinaciones de lanzador y tipo que no usamos para calibrar. En movimiento lateral baja de 2.93 a 0.88 pulgadas, y en velocidad al plato de 1.32 a 0.57 mph.

Si escalas todo sólo por la densidad del aire, sin la corrección de Reynolds, subestimas el efecto en cerca de un tercio.

## 4.2 CALIDAD Y ROBUSTEZ

**Antes de ver el $R^2$.** El $R^2$ de un lanzamiento suelto es bajo en cualquier Stuff+, porque su desenlace es casi azar y Stuff+ no sabe dónde cayó la pelota. Nuestro modelo está en el techo de lo que la física sola puede predecir. Probamos ocho variantes con las mejoras usuales (calidad de contacto del batazo, arsenal, frenado relativo al aire y variables de física) y ninguna se separa del ruido (Anexo C). Lo que falta para un $R^2$ alto es dónde cayó la pelota, y por definición eso no entra en Stuff+. Por eso lo juzgamos como se juzga en Grandes Ligas, por si ordena carreras, si es estable y si anticipa el año siguiente.

| PRUEBA | CAPA | VARIABLES | RMSE | $R^2$ | CORRELACIÓN |
|---|---|---|---|---|---|
| Modelo nulo, promedio por conteo | | | 0.26810 | 0.0000 | 0.005 |
| Holdout de lanzador | Stuff+ | 16 | 0.26797 | 0.0010 | 0.036 |
| Holdout de lanzador | Location+ | 23 | 0.26235 | 0.0425 | 0.207 |
| Holdout de lanzador | Pitching+ | 33 | 0.26225 | 0.0432 | 0.208 |
| Holdout de temporada | Stuff+ | 16 | 0.26626 | 0.0009 | 0.035 |
| Holdout de parque | Stuff+ | 16 | 0.27707 | $-0.0005$ | 0.022 |

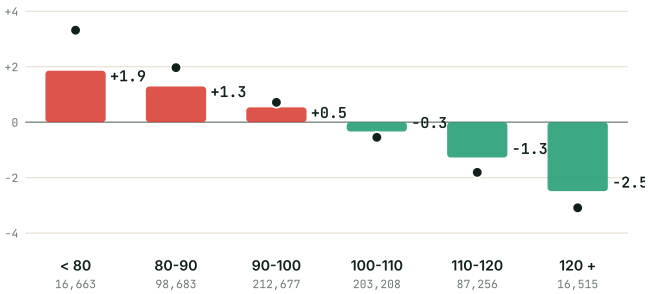
Las tres capas vencen al modelo nulo con lanzadores que nunca vieron. Stuff+ tiene el $R^2$ más bajo de las tres porque no ve la ubicación, y así debe ser. Location+ y Pitching+ suben porque suman dónde llegó la pelota y el conteo.

**El holdout de parque no falla en el orden, falla en el nivel.** Un modelo entrenado sin altura ordena bien los lanzamientos en altura (correlación positiva), pero espera las carreras de nivel del mar. En altura todo cuesta más, y por eso su $R^2$ queda apenas bajo cero. Esa diferencia de nivel es justo el efecto que medimos, y por eso transferimos la forma en lugar de confiar en un modelo entrenado en otro aire.

**Stuff+ es un rasgo del lanzador, no suerte.** Partimos los lanzamientos de cada lanzador en dos mitades al azar (602 lanzadores con al menos 150 por mitad). Su Stuff+ en una mitad correlaciona 0.988 con el de la otra. Sus carreras, sólo 0.293. Las carreras de unos cientos de lanzamientos son casi ruido, y la forma no.

**Anticipa el año siguiente sin necesitar historial.** En 336 pares de temporadas seguidas (2024 a 2025 y 2025 a 2026, 250 lanzadores), el Stuff+ de un año correlaciona 0.22 con las carreras del siguiente. Las carreras del año anterior, 0.18. Esa diferencia no es concluyente, pero sumar Stuff+ a las carreras pasadas sí mejora la predicción (0.027 de $R^2$, IC 0.004 a 0.071). Stuff+ lo logra con la sola física, así que a un prospecto lo puedes calificar desde su primera sesión de Trackman (Anexo C).

**Calibración.** La escala ordena carreras cuando agregas lanzamientos, que es donde importa.



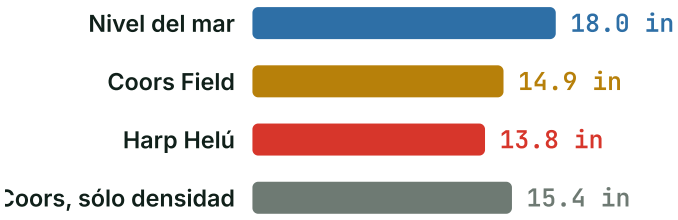

Carreras por cada 100 lanzamientos según el Stuff+ fuera de muestra. Barras, lo observado. Puntos, lo predicho.

La relación baja en los seis tramos, sin excepción. De un extremo al otro hay unas 4.3 carreras por cada 100 lanzamientos, sólo por la forma. Entre 80 y 120 está el 95 % de los lanzamientos, y ahí lo predicho queda a menos de 0.7 carreras de lo observado. En los extremos el modelo exagera un poco, en la dirección correcta.

# 5. HIPÓTESIS

## 5.1 H1 · LA BAJA DENSIDAD REDUCE EL MOVIMIENTO. SE CONFIRMA

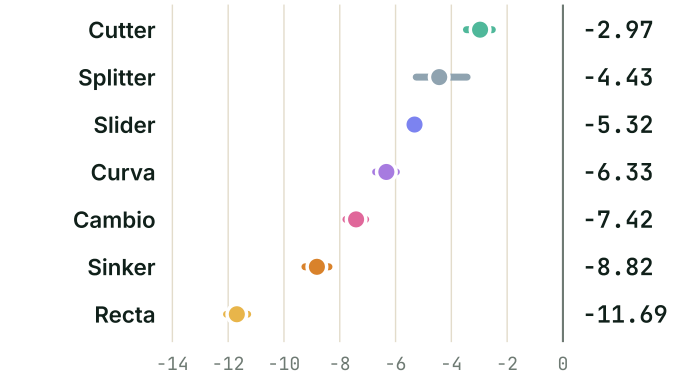
**La física reproduce a Nathan.** Tomamos una recta con 18.0 pulgadas de quiebre a nivel del mar y la volamos en otros aires con el integrador, calibrado sólo con datos de la LMB.




Quiebre total de una recta de 18 pulgadas a nivel del mar, volada en otros aires. Nathan estima 14 a 15 en Coors.

Una curva típica de 78 mph y 12.4 pulgadas de quiebre total cae 1.4 pulgadas menos en Coors y 2.0 menos en el Harp Helú. Su quiebre total baja 2.5 y 3.4 pulgadas.

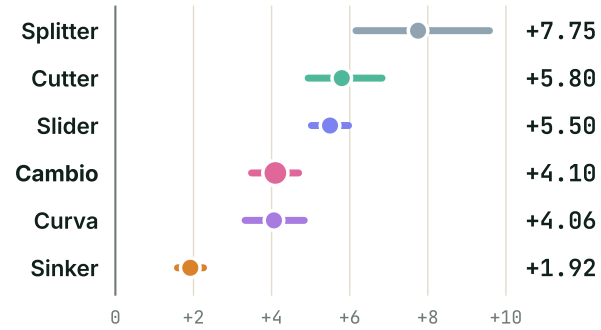
**Todos los tipos pierden Stuff+.** En los siete el intervalo de 95 % queda bajo cero.




Cambio medio de Stuff+ por tipo al pasar al Harp Helú, con su intervalo de 95 % (bootstrap por lanzador).

La recta pierde casi cuatro veces lo que pierde el cutter. En carreras, su pérdida equivale a 1.6 carreras más por cada 100 rectas. La curva gana elevación, o sea que cae menos, y por eso pierde. Su valor es caer. Entre los seis tipos con mediciones suficientes, el que más movimiento pierde en la cancha es el que más Stuff+ pierde (correlación de rangos $-0.83$, $p = 0.04$).

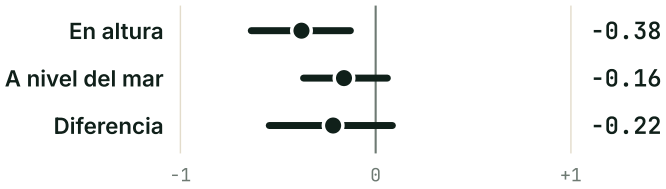
## 5.2 H2 · EL CAMBIO GANA VALOR RELATIVO. SE CONFIRMA EN PARTE




Cuántos puntos menos pierde cada tipo que la recta del mismo lanzador, con su intervalo de 95 %.

El cambio sí gana valor contra la recta, 4.1 puntos, y no es casualidad. Pero queda cuarto de seis, empatado con la curva y detrás del splitter, el cutter y el slider. La razón está en su forma. Un cambio de derecho se mueve unas 12 pulgadas hacia el lado del brazo, y ese movimiento también lo paga. En altura no gana el que engaña por velocidad. Gana **el que nunca dependió del movimiento**. Por eso el splitter, que engaña por velocidad y además casi no gira, gana más que todos.

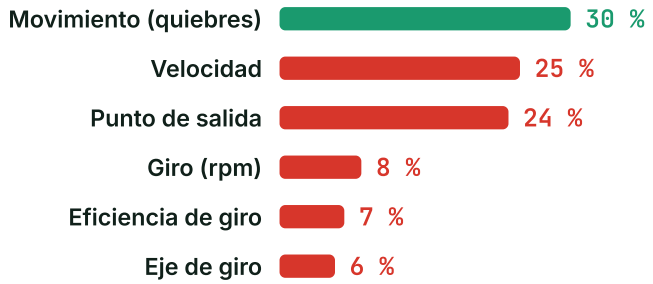
## 5.3 H3 · LOS LANZADORES DE RODADOS VALEN MÁS EN ALTURA. SE CONFIRMA EN PARTE




Carreras por cada 100 lanzamientos por cada 10 puntos más de rodados, con su intervalo de 95 %. Negativo previene carreras.

En altura los rodados previenen carreras con claridad. A nivel del mar el efecto no se distingue de cero. La diferencia va en la dirección de la hipótesis ($p = 0.08$, una cola), pero no llega al 95 %. Por tercios, los lanzadores con pocos rodados (34 %) permiten 1.76 carreras más por cada 100 lanzamientos en altura, y los de muchos rodados (50 %) sólo 1.37. En los batazos de la liga, el rodado sube de 40.5 % a 44.8 % en altitud extrema y el jonrón por elevado sube de 12.4 % a 16.3 %.

### 5.4 H4 · IMPORTA CUANTO SE MUEVE, NO CUANTO GIRA. SE CONFIRMA




Peso de cada grupo de variables dentro de Stuff+ (ganancia total de los árboles).

El modelo sí usa el giro. Es la tercera de 16 variables, pero sobre todo para distinguir un tipo de lanzamiento de otro. En el experimento controlado, 100 revoluciones más **con el mismo movimiento** no cambian Stuff+ (0.01 puntos). Una pulgada más de elevación **con el mismo giro** suma 2.59. Y la ventaja del movimiento es la que el aire se lleva. Una recta B con 2,150 rpm y 18.0 pulgadas de elevación vale 107.7 a nivel del mar, 19.2 puntos más que una recta A que gira más pero a la que ese giro casi no mueve (2,650 rpm y 13.5 pulgadas, 88.5). En el Harp Helú B vale 86.1 y A 80.0. La ventaja se reduce a un tercio.

## 6. LO QUE SIGNIFICA PARA EL CLUB

### 6.1 LA ALTITUD BORRA LA VENTAJA DEL BUENO

Partimos las rectas en quintiles por su Stuff+ a nivel del mar. El castigo no es parejo. El quintil más bajo pierde 3.8 puntos (de 89.6 a 85.8). El más alto pierde 19.4 (de 116.4 a 97.1) y queda bajo el promedio. Lo que separa a una recta de élite de una mediocre es el movimiento, y el movimiento es lo que el aire se lleva. Entre el 1 % mejor calificado, el slider pasa de 24 % a 52 % y la recta cae de 41 % a 1 %.

**Tres estadios, no dos.** El mismo lanzamiento, volado con el aire de cada categoría.

| | NIVEL DEL MAR | ALTITUD MEDIA | ALTITUD EXTREMA |
|---|---|---|---|
| Índice de aire | 1.000 | 0.898 | 0.853 |
| Stuff+ de la liga | 103.1 | 97.1 | 94.8 |
| Recta | 102.5 | 93.9 | 90.9 |
| Cutter | 102.1 | 100.6 | 99.2 |

La altitud media ya cobra el 73 % del castigo. Un lanzador que viene de un parque de altura media llega al Harp Helú con la mayor parte del ajuste hecho.

### 6.2 EL PERFIL FÍSICO IDEAL

Promediamos el 1 % mejor calificado en cada aire, sólo lanzadores derechos y sólo lanzamientos reales. Una rejilla libre produciría combinaciones que ningún lanzador hace.

| VARIABLE | ÉLITE A NIVEL DEL MAR | ÉLITE EN ALTURA | MEDIANA DE LA LIGA |
|---|---|---|---|
| Velocidad (mph) | 88.3 | 85.1 | 88.9 |
| Elevación (in) | 4.4 | −3.3 | 9.2 |
| Movimiento lateral (in) | 0.7 | −4.4 | 7.3 |
| Movimiento total (in) | 17.3 | 11.3 | 14.7 |
| Eficiencia de giro | 0.84 | 0.55 | 0.81 |
| Giro (rpm) | 2,554 | 2,504 | 2,328 |

La élite de altura es de rompientes que caen y cortan hacia el guante, no de rectas que suben. Gira casi lo mismo que la otra, pero convierte mucho menos de ese giro en movimiento. No depende del empuje del aire, que es justo lo que la altura le quita.

### 6.3 POR LANZADOR

Analizamos 561 lanzadores con al menos 300 lanzamientos. **21 aguantan**, es decir, pierden menos de 3.7 puntos (media carrera por cada 100 lanzamientos), y 354 pierden más de 7.4 (una carrera). Los que más pierden son buenos a nivel del mar porque se mueven mucho. Lanzador 174 (recta y cambio) baja de 111.3 a 92.8. Tu perfil de fichaje es Lanzador 1099 (cutter, slider y curva).

Vale 110.2 a nivel del mar y 109.8 en el Harp Helú, pierde 0.4 puntos, el segundo mejor Stuff+ de la liga en altura, y es de los más constantes entre juegos ($\pm 2.6$ contra $\pm 4.5$ de la mediana).

### 6.4 LO QUE DICE EL CAUSAL FOREST

**El costo promedio es firme.** Lanzar en altura cuesta **1.52 carreras más por cada 100 lanzamientos** (IC 90 % de 1.27 a 1.78), medido en el marcador y sin usar Stuff+. Es la misma dirección que predice la física. ¿Cuánto de ese costo es el lanzamiento? Un modelo entrenado sólo a nivel del mar atribuye al vuelo del lanzamiento 0.57 de las 1.49 carreras de más que hay en altura, el 39 % (IC 34 a 44 %, Anexo C). El resto lo pone sobre todo el batazo, que en altura viaja 31 pies más. La pérdida de Stuff+ de la liga (8.3 puntos, 1.12 carreras) sale mayor, porque la caída de velocidad también recoge parte del entorno (sección 8).

**Las diferencias entre lanzadores no se sostienen.** El bosque estima efectos entre 1.27 y 1.76, y para 331 de 333 lanzadores el intervalo incluye el promedio. En la prueba fuera de muestra, el castigo observado no sube con el efecto predicho (pendiente de $-1.95$, IC 95 % de $-4.0$ a $+0.2$). El bosque sí aprende la misma dirección que Stuff+ (correlación de 0.17 fuera de muestra, $p = 0.002$), pero las carreras de unos cientos de lanzamientos tienen demasiado azar para confirmarlo lanzador por lanzador.

Ese resultado justifica el diseño del trabajo. Para separar a un lanzador de otro necesitas algo estable, y eso es su forma, medida con física. Las carreras confirman el tamaño del castigo promedio.

**La pregunta táctica, en casa sí cambia la respuesta.** Comparamos cuatro pares de lanzamientos con 150,000 lanzamientos cada uno y medimos el efecto en 48 celdas (12 conteos, dos lados del bateador y dos entornos). Slider en vez de cambio ahorra 0.31 carreras por cada 100 lanzamientos a nivel del mar y 1.01 en altura. De las 10 celdas donde el intervalo de 90 % no cruza el cero, 9 están en altura y todas favorecen al slider, sobre todo contra el bateador del lado contrario y con el conteo en contra (2 bolas o más). Es lo que predice H1, porque el cambio pierde más movimiento que el slider. A nivel del mar, con 3 bolas y bateador del mismo lado, la recta le gana al cambio por 3 a 5 carreras por cada 100. Con 48 celdas por par esperarías unas 5 falsas por azar, así que lee las celdas sueltas como pistas y el patrón como el resultado. Las tablas completas están en la pestaña Causal Forest del dashboard.

## 7. RECOMENDACIONES

**Fichajes.** No pagues de más por movimiento. Una recta del quintil más alto llega a 2,240 metros valiendo 97.1 en lugar de 116.4. El mercado cobra esa prima a nivel del mar, y tú la pagarías por algo que en tu estadio no existe.

**Perfil.** Busca arsenales de cutter, slider y splitter, y lanzadores que provoquen rodados. En altura un elevado viaja 31 pies más (de 292 a 323) y sale del parque 16.3 % de las veces contra 12.4 %.

**Rotación.** Abre en casa con los lanzadores que aguantan (pestaña Lanzadores del dashboard). Los que pierden mucho rinden más de visitante.

**En el juego.** En casa, cuando el pitcher va atrás en el conteo contra un bateador del lado contrario, pide slider antes que cambio. El Causal Forest táctico encuentra 10 celdas firmes en ese par, y 9 están en altura y favorecen al slider.

**Prospectos.** Hazte cinco preguntas, en este orden. 1. ¿Cuánto de su valor es movimiento? Si su Stuff+ está en el quintil más alto por su quiebre, esa ventaja no viaja a la Ciudad de México. 2. ¿Cuánto de su giro se vuelve movimiento? La eficiencia alta ayuda a nivel del mar y te expone en altura (élite de altura 0.55 contra 0.84). 3. ¿Su arsenal se apoya en cutter, slider o splitter, o en recta y curva? El primero pierde poco y el segundo llega devaluado. 4. ¿Provoca rodados? Es el único batazo que el aire no ayuda. 5. Pasa sus números de Trackman por el simulador. Te da su Stuff+ en los dos estadios.

## 8. LÍMITES

- **No identificamos estadios.** La altitud extrema agrupa varios parques, y el Harp Helú es el más alto.
- **No separamos aire de clima.** El índice de arrastre junta densidad, temperatura y humedad. Sirve para predecir movimiento, no para atribuirlo sólo a la altitud.
- **No modelamos al bateador.** Desde la física, el barril casi no se puede predecir (1 % de habilidad).
- **Stuff+ no es causal.** Es un modelo de valoración. Para las preguntas de qué hubiera pasado usamos el Causal Forest, que confirma el costo promedio pero no separa a un lanzador de otro.
- **El exponente de Reynolds es empírico.** Lo calibramos y verificamos fuera de muestra, pero no sale de primeros principios.
- **Stuff+ ve la caída de velocidad, que también refleja el aire.** Lo probamos sin las tres variables de frenado y entrenando sólo con juegos a nivel del mar. El orden de los tipos se mantiene en los dos casos (correlación

de rangos 0.96), pero la pérdida de la liga baja de 8.3 a 6.2 y 5.1 puntos. La versión de nivel del mar ya no le ganaba al modelo nulo con lanzadores nuevos, y por eso no es la principal (Anexo C).

- **El simulador exagera la pérdida.** Califica una forma típica y no la población, y sus pérdidas salen unos 4 puntos mayores que las de la tabla por tipo. Sirve para comparar lanzamientos entre sí.

## 9. REPRODUCCIÓN

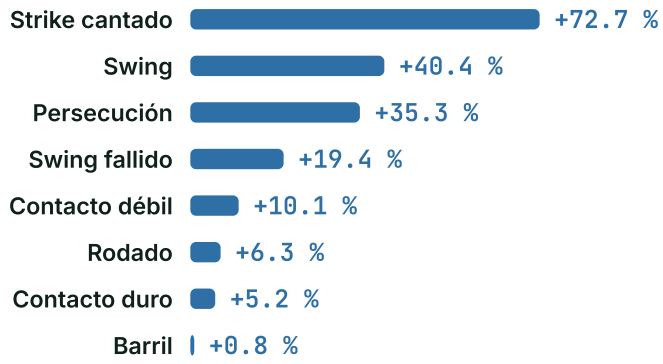
El código, los modelos entrenados y los pasos para correr todo están en `github.com/dulongski/diablos-hackathon`. El dashboard corre completo en el navegador.

## REFERENCIAS


- Athey, S., Tibshirani, J. y Wager, S. (2019). Generalized random forests. *Annals of Statistics*, 47(2).
- Chernozhukov, V. y coautores (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1).
- Chernozhukov, V., Demirer, M., Duflo, E. y Fernández Val, I. (2018). Generic machine learning inference on heterogeneous treatment effects in randomized experiments. NBER Working Paper 24678.
- Efron, B. (1979). Bootstrap methods, another look at the jackknife. *Annals of Statistics*, 7(1).
- Huang, G. y Hsu, M. (2021). Big data analytics in baseball, a review. *SAGE Open*, 11(4).
- Ke, G. y coautores (2017). LightGBM, a highly efficient gradient boosting decision tree. *NeurIPS*.
- Nathan, A. *The effect of altitude on baseball trajectories.* The Physics of Baseball.
- SABR. *High altitude offense.* Baseball Research Journal.
- Tango, T., Lichtman, M. y Dolphin, A. (2007). *The Book, Playing the Percentages in Baseball.*
- Wager, S. y Athey, S. (2018). Estimation and inference of heterogeneous treatment effects using random forests. *JASA*, 113(523).

# ANEXO A · MODELOS DE COMPONENTE

Estos modelos explican de dónde sale el valor y no entran en Stuff+. La habilidad mide cuánto mejoran sobre la tasa base, con holdout de lanzador.




Habilidad de cada modelo de componente, cuánto mejora su Brier sobre la tasa base, con lanzadores que no vio.

El arsenal se nota donde actúa su mecanismo, en el swing fallido. Ahí la habilidad sube de 4.5 % con sólo la física a 18.9 % con ubicación y a 19.4 % con arsenal y secuencia.

# ANEXO B · GLOSARIO

| TÉRMINO | QUÉ SIGNIFICA |
|---|---|
| Stuff+ | Calidad del lanzamiento por cómo sale de la mano. 100 es el promedio y 10 puntos son una desviación estándar |
| Location+ y Pitching+ | La misma escala, sumando ubicación y conteo, y después arsenal y secuencia |
| Elevación | Cuánto cae menos una recta de lo que caería sin giro |
| Eficiencia de giro | La parte del giro que produce movimiento |
| Rodado y elevado | Batazo por el suelo y batazo por el aire |
| Arsenal | Los tipos que un lanzador usa al menos 8 % de las veces |
| Tipos de lanzamiento | Recta, sinker, cutter, slider, curva, cambio y splitter. El anexo del dashboard dibuja el vuelo de cada uno, de la mano al plato |
| Intervalo de confianza de 95 % | El rango donde está el valor real con alta probabilidad. Si no cruza el cero, el efecto no es casualidad |

# ANEXO C · PRUEBAS DE ROBUSTEZ

Estas pruebas responden las dudas que un jurado técnico tendría al ver un $R^2$ bajo o un efecto de la altura grande. Todas usan predicciones fuera de muestra y los intervalos de 95 % salen de un bootstrap por lanzador.

**Holdout de parque con física.** Entrenamos con nivel del mar y predijimos los 183,267 lanzamientos de altitud extrema de 897 lanzadores que el modelo no vio, cada uno con su forma real y con la misma pelota volada a nivel del mar.

| POR CADA 100 LANZAMIENTOS EN ALTURA | CARRERAS | IC 95 % |
|---|---|---|
| Exceso observado sobre lo que espera un modelo de nivel del mar | +1.49 | +1.34 a +1.66 |
| Parte que explica el vuelo del lanzamiento | +0.57 | +0.54 a +0.61 |
| Resto, sobre todo el batazo | +0.92 | +0.76 a +1.10 |

La física del lanzamiento explica 39 % del exceso (IC 34 a 44 %). Dentro de la altura el modelo ordena con correlación +0.017 (IC +0.012 a +0.022), y su $R^2$ con el nivel corregido es −0.00094. Por tipo de lanzamiento, el exceso observado no sigue el orden de la pérdida física (correlación de rangos −0.57, 7 tipos). El exceso por tipo lo domina el batazo y en varios tipos hay pocos lanzadores, así que la física se lee en el total, no tipo por tipo.

**Discriminación en carreras.** Diferencia en carreras por cada 100 lanzamientos entre el 10 % peor y el 10 % mejor calificado, fuera de muestra.

| CAPA | DIFERENCIA | IC 95 % |
|---|---|---|
| Stuff+ | 3.31 | 2.98 a 3.64 |
| Location+ | 18.98 | 18.71 a 19.30 |
| Pitching+ | 19.13 | 18.76 a 19.55 |

**Calidad contra mezcla de lanzamientos.** Correlación entre dos mitades al azar de los lanzamientos de cada lanzador. Stuff+ tal cual 0.988, contra el promedio de su tipo 0.989 (IC 0.987 a 0.990), sólo rectas 0.990, sólo la mezcla de tipos 0.967 y carreras reales 0.293.

**Año siguiente.** 336 pares de temporadas seguidas de 250 lanzadores.

| LO QUE MIDES ESTE AÑO | CARRERAS DEL SIGUIENTE | SWING FALLIDO DEL SIGUIENTE |
|---|---|---|
| Stuff+ | +0.219 (+0.11 a +0.32) | +0.165 (+0.05 a +0.27) |
| Sus carreras | +0.184 (+0.09 a +0.28) | +0.164 (+0.08 a +0.24) |
| Su swing fallido | +0.214 (+0.11 a +0.31) | +0.555 (+0.45 a +0.64) |

Sumar Stuff+ a las carreras pasadas sube el $R^2$ de las carreras futuras en 2.7 puntos porcentuales (IC 0.4 a 7.1).

**La combinación ponderada que sugiere el reto.** 9 modelos de componente con las variables de Stuff+, incluida la probabilidad de out en el turno, combinados con pesos aprendidos por regresión fuera de muestra.

| VERSIÓN | $R^2$ | RMSE | DIFERENCIA 10 % | MITADES |
|---|---|---|---|---|
| Directo en carreras | 0.00098 | 0.26797 | 3.31 | 0.988 |
| Combinación ponderada | 0.00131 | 0.26793 | 3.29 | 0.985 |

Las dos versiones correlacionan 0.75 entre sí.

**Sensibilidad a la caída de velocidad.** Pérdida de Stuff+ al pasar a altitud extrema con tres versiones del modelo.

| TIPO | LA QUE USAMOS | SIN FRENADO | SÓLO NIVEL DEL MAR |
|---|---|---|---|
| Recta | −11.6 | −10.6 | −7.7 |
| Slider | −5.3 | −1.4 | −3.3 |
| Curva | −6.2 | −4.4 | −4.0 |
| Cambio | −7.3 | −4.5 | −3.9 |
| Sinker | −8.7 | −7.5 | −5.0 |
| Cutter | −3.0 | +0.5 | −0.8 |
| Splitter | −4.5 | −1.6 | −2.7 |

El orden de los tipos coincide con correlación de rangos 0.96 sin frenado y 0.96 entrenando sólo a nivel del mar.

**Mejoras que probamos y no cambian el resultado.** Calificamos cada batazo por lo que se espera de su velocidad de salida y su ángulo, no por si fue hit, metimos dentro de Stuff+ las diferencias contra la recta del mismo lanzador, dividimos el frenado entre el aire del juego y sumamos variables de física (movimiento en dirección del brazo, desfase entre el eje de giro y el movimiento, consistencia del punto de salida). Misma validación por lanzador, todo medido contra las carreras reales.

| VERSIÓN | $R^2$ | DIFERENCIA 10 % | MITADES | AÑO SIGUIENTE |
|---|---|---|---|---|
| La que usamos | 0.00100 | 3.31 | 0.984 | 0.230 |
| Batazo por calidad de contacto | 0.00109 | 3.20 | 0.982 | 0.234 |
| Arsenal contra la recta dentro de Stuff+ | 0.00094 | 3.27 | 0.987 | 0.209 |
| Contacto y arsenal | 0.00110 | 3.24 | 0.983 | 0.218 |
| Frenado relativo al aire del juego | 0.00094 | 3.18 | 0.984 | 0.231 |
| Movimiento en dirección del brazo | 0.00113 | 3.47 | 0.982 | 0.219 |
| Desfase del eje de giro | 0.00107 | 3.28 | 0.984 | 0.242 |
| Consistencia del punto de salida | 0.00099 | 3.39 | 0.986 | 0.200 |
| Las cuatro de física juntas | 0.00110 | 3.36 | 0.985 | 0.195 |

Ninguna se separa de la que usamos más allá del ruido. La mejor diferencia del 10 % (dirección del brazo) queda dentro del intervalo de la nuestra y empeora el año siguiente. Stuff+ ya está en el techo de lo que la física del lanzamiento sola predice de un lanzamiento suelto. Lo que falta para un $R^2$ alto es dónde cayó la pelota, y eso por definición no entra en Stuff+.

*Usamos los datos de la LMB sólo para esta competencia. Este documento presenta resultados, no datos.*